

COUNCIL AGENT

開發歷程簡報

從三階段管線到 Trust Tier

Spec-driven · Tool-First · 漸進式安全

OpenRouter + CrewAI CLI 框架

現行版本 v1.0.0-beta.2

策略 Tool-First 漸進式

方法 OpenSpec 規格驅動

日期 2026-08-12

專業 · 極簡 · 證據導向

本日綱要

以版本軸線回顧能力成長、安全強化與目前公開測試狀態。

01 專案定位與核心架構

02 開發策略：Tool-First + Spec-driven

03 版本時間軸總覽

04 能力奠基期（v0.1–v0.5）

05 安全補強期（v0.6–v0.9）

06 清債與信任框架（v0.9.1–v1.0-beta）

07 現況、限制與下一步

專案定位

Council Agent：讓 AI 以可驗證、可追溯的方式在本機工作區完成任務。



校驗失敗時進入 Escalation，修正後以原成功標準重新驗證；全程可搭配 session 與 audit 留下證據。

兩條並行的開發軸線

Tool-First 漸進式

先讓 Execution Crew 在本機工作區真實動手；安全機制自 v0.6 起逐步補強，避免過早阻塞主線。

原則：最小改動 · 邊界先行 · 安全外掛 · 證據導向校驗


Spec-driven + OpenSpec

每個 feature 先有 proposal / design / tasks / spec delta，再依階段實作：純函式 → CLI 接線 → CrewAI 掛載 → e2e。

驗證門檻：pytest + openspec validate --changes/--specs

版本時間軸總覽

從骨架到公開 beta：能力先落地，信任機制後收斂。



能力奠基期 v0.1 → v0.5

把「能計劃、能改檔、能跑測、能校驗」打通成可用 MVP。

v0.1

專案骨架

Typer CLI、三階段 Crew、OpenRouter、YAML Preset

v0.2

Tool 基礎層

read / write / list / delete / run_command → ToolResult

v0.3

Workspace 邊界

WorkspaceGuard、路徑穿越防護、敏感路徑黑名單

v0.4

測試整合

run_tests、結構化報告、max_tool_calls、Verification 讀摘要

v0.5

Sandbox MVP

sandbox init/status、Execution 掛載 tools、session 紀錄

安全補強期 v0.6 → v0.9

功能穩定後，逐步補上分類、確認、審計與專案政策。

v0.6 指令分類

read / write / dangerous · pattern 啟發式分類 · 危險指令預設守門

v0.7 互動確認

TTY ask · --yes auto · 無 TTY refuse · 寫入 / 危險操作闖道

v0.8 審計日誌

結構化 JSONL · audit show / export · session 關聯可追溯

v0.9 政策設定

council.policy.yaml · allow / deny 指令 · denied_paths 聯集

清債序列 v0.9.1 → v0.9.9

一版一主要問題：關閉與 v1.0 DoD 衝突的 P0 / P1，再談 Trust Tier runtime。

0.9.1

Shell containment

未知 / 混淆 fail-closed

0.9.2

Policy Middleware

唯一 dispatcher

0.9.3

Policy trust boundary

只可縮權 · fail-fast

0.9.4

Audit integrity

redaction · sequence

0.9.5

Principal scope

key ≠ 授權主體

0.9.6

Session auth

--yes ≠ 認證

0.9.7

Trust grant store

workspace 外可撤銷

0.9.8

Decision matrix

與 ConfirmMode 分離

0.9.9

Evidence closure

escalation 後再驗

信任框架 v1.0-alpha → beta.2

Tier 0 預設 高敏感操作需確認；最保守起點	Tier 1 安全自動 低風險指令可自動；寫入仍受控	Tier 2 全自動 需明確啟用；非 --yes 的替代
---	---	---

alpha.1	Trust Tier runtime 入場
beta.1	公開測試文件 · stop-line
beta.2	Agent 矩陣 PASS (含 LIVE-01)

模組演進地圖

核心管線保持穩定；tools → sandbox → security 分層擴充。

介面	cli.py · presets · settings
協調	orchestrator · types · crews
工具	filesystem · shell · tracker
邊界	WorkspaceGuard · session
安全	classifier · confirm · policy · audit · trust

現況 v1.0.0-beta.2

■ 已交付

- 三階段管線與 Escalation
- Tools + Sandbox + Session
- 指令分類 / 確認 / 審計 / 政策
- Trust Tier 0/1/2 + matrix-v2
- Agent 公開測試矩陣 ACCEPTED
- LIVE-01 PASS

■ 仍待 / 已知限制

- Audit predecessor hash chain (GA)
- 獨立真人 TTY 驗證
- 完整 OS / 容器級 sandbox (非宣稱範圍)
- 剩餘 GA Definition of Done

已知邊界：shell / WorkspaceGuard 非 OS sandbox；ConfirmMode / --yes ≠ Trust Tier；project policy 不能設定 tier。

沿途累積的硬性原則

先規格，再程式

OpenSpec change 就緒後才實作；Non-goals
對齊 ROADMAP

不可跳步整合

函式 → 接線 → 框架掛載 → e2e，每階 pytest
全綠

可預期錯誤不 throw

Tool 回傳 ToolResult(success=False)

安全不可誇大

啟發式分類 ≠ 完整信任；文件必須說清楚邊界

驗證三件套

pytest + validate --changes + validate --specs

發版有流程

archive → release 分支 bump → tag →
文件同步

NEXT

通往 GA 的下一哩路

01

補齊 audit predecessor-linked hash chain

完整性可驗證、防事後竄改

02

完成獨立真人 TTY 測試與證據封存

補齊 beta 後仍 defer 的人工驗證

03

對照 v1.0 DoD 關閉剩餘項目

trust CLI、威脅模型文件、邊界聲明一致

04

發版流程：archive → release → tag → ROADMAP

openspec/changes 不得留 active change

COUNCIL AGENT

能動手，也要能守門。

從 Tool-First MVP 到 Trust Tier beta——
規格驅動、漸進整合、證據閉環，是這段歷程的主軸。

現行版本 v1.0.0-beta.2 · 2026-08-12

配色：Primary #7E9F35 · Accent #A7383D · Accent #562A72