

開發歷程簡報

從三階段管線到 Trust Tier 公開測試
Tool-First · Spec-driven · OpenSpec



現況基線 v1.0.0-beta.2

資料截止 2026-08-11 · 簡報產出 2026-08-12

目錄

這份簡報帶你走完一條版本路徑

- 01 專案定位與策略
- 02 版本時間軸總覽
- 03 能力奠基：Tools → Sandbox (v0.2–v0.5)
- 04 安全補強：Classifier → Policy (v0.6–v0.9)
- 05 清債序列：通往 v1.0 的九個修補 (v0.9.1–v0.9.9)
- 06 信任框架與公開測試 (v1.0-alpha → beta.2)
- 07 現況能力、已知限制與下一步

專案定位

OpenRouter + CrewAI 三階段 CLI 框架



兩條並行原則

Tool-First 漸進式

先讓 Execution 能在本機工作區動手
邊界先行：WorkspaceGuard 限制 cwd
安全以 middleware 後補，不阻塞主線
Verification 讀真實 tool / pytest 結果

Spec-driven + OpenSpec

先提案 (proposal / design / tasks / delta)
再依 tasks 漸進整合，不可跳步
feature 分支對應一個 change
提交前必須通過 ./scripts/check.sh

版本時間軸

v0.1 → v1.0.0-beta.2



策略節奏：先可用 → 再可控 → 再可信任。紅色 / 紫色標示安全與信任模組。

能力奠基 v0.2–v0.5

讓 Agent 真的能動手，而不是只會說話

v0.2 Tool 基礎層

read / write / list / delete
run_command
統一 ToolResult

v0.3 Workspace 邊界

WorkspaceGuard
路徑穿越防護
敏感路徑黑名單

v0.4 測試整合

run_tests + pytest 報告
Verification 讀摘要
max_tool_calls

v0.5 Sandbox MVP

council sandbox CLI
Execution 掛載 tools
session 紀錄

v0.5 DoD: CRUD 檔案、跑 pytest、擋穿越、Verification 對照真實結果、tool 呼叫上限。

安全補強 v0.6–v0.9

功能穩定後，把風險關進政策與審計

v0.6

指令分類

read / write / dangerous pattern 啟發式

v0.7

互動確認

TTY ask · --yes · 無 TTY refuse

v0.8

審計日誌

.council/audit/ + show / export

v0.9

政策設定

council.policy.yaml allow/deny + denied_paths

提醒：分類是 pattern 啟發式，此時尚未宣稱完整信任框架。

清債序列 v0.9.1–v0.9.9

一版只解一個主要問題，為 Trust Tier 清場

0.9.1

Shell containment

未知 / 混淆指令 fail-closed

0.9.2

Policy Middleware

唯一 dispatcher + SecurityContext

0.9.3

Policy trust boundary

專案政策只能縮權

0.9.4

Audit integrity

redaction · sequence · 控制面

0.9.5

Principal / scopes

區分 provider key 與授權範圍

0.9.6

Session auth

高權限 step-up; --yes ≠ 認證

0.9.7

Trust grant store

使用者擁有、可 revoke

0.9.8

Decision matrix

與 ConfirmMode 分離、可測

0.9.9

Evidence closure

escalation 後重新驗證

信任框架與公開測試

v1.0.0-alpha.1 → v1.0.0-beta.2

Tier 0

預設

所有操作需確認

Tier 1

安全自動

安全指令自動執行

Tier 2

全自動

需明確啟用

- alpha.1: 啟用 Trust Tier 0/1/2 runtime 與 CLI --trust-tier
- beta.1: schema 凍結; Agent 公開測試矩陣 (含 LIVE-01) PASS (ACCEPTED GATE A)
- beta.2: 承接凍結語意的公開測試後續基線; 獨立真人 TTY 仍待後續 beta
- 明確分離: ConfirmMode / --yes ≠ Trust Tier; 專案政策不能設定 tier

架構演進一覽

模組以顏色區隔：綠 = 核心能力、紅 = 風險開道、紫 = 信任 / 政策

crews / orchestrator

三階段管線與協調

—
planning
execution + tools
verification + evidence

tools / sandbox

動手與邊界

—
filesystem / shell
WorkspaceGuard
session

security 開道

分類 · 確認 · 審計

—
classifier
confirm modes
audit JSONL

trust / policy

決策與授權

—
middleware
policy.yaml
Trust Tier matrix

現況快照 v1.0.0-beta.2

已交付 vs 已知限制

已就緒

三階段管線 + Escalation
Tools / Sandbox / Session
Classifier + Confirm + Audit
Policy middleware (唯一路徑)
Trust Tier 0/1/2 + matrix-v2
Agent 公開測試門檻通過

尚未 / 限制

Audit predecessor hash chain (GA)
非 OS / 容器級 sandbox
run_tests 會執行專案程式碼
真人獨立 TTY 測試待補
policy 不可設定 trust tier
--yes 不是 Tier 2

下一步：邁向 GA

v1.0 DoD 剩餘焦點



完整性

審計日誌 predecessor-linked hash chain 與可匯出完整性證明



體驗驗證

獨立真人 TTY 手冊走完，補齊 beta 後續證據



文件與威脅模型

安全模型、政策指南、威脅模型簡述齊備



發版紀律

active change 歸檔、release 分支 bump、ROADMAP / config 同步

附錄：品牌色階

本簡報實際使用的 Primary / Accent 分工

Primary 橄欖綠

畫面基調、標題列、核心能力模組




Secondary 磚紅

風險、限制、危險狀態強調



Secondary 紫

信任、政策、清償與 Tier 模組



先動手，再控權，後可信

這條路不是一次堆出完整安全機制，
而是用 Spec-driven 把每一次增量變成可驗證的基線。

目前站在 v1.0.0-beta.2：信任語意已凍結，公開測試已過門，
下一步是把完整性與真人驗證補齊，穩穩走向 GA。



配色：主色橄欖綠 #7E9F35 · 強調磚紅 #A7383D · 強調紫 #562A72